

Systeme de recommandation par filtrage collaboratif

Rapport de fin d'etudes - document de test, contenu fictif

1. Introduction

Le volume de contenus disponibles sur les plateformes numeriques a connu une croissance telle que la selection manuelle est devenue impraticable pour l'utilisateur final. Un catalogue de plusieurs centaines de milliers d'articles ne peut etre explore exhaustivement, et la majorite des elements pertinents pour un utilisateur donne ne seront jamais decouverts par simple navigation. Les systemes de recommandation repondent a ce probleme en construisant, pour chaque utilisateur, une liste ordonnee d'elements susceptibles de l'interesser. Leur importance economique est aujourd'hui considerable : une part majoritaire des contenus consommes sur les grandes plateformes de streaming provient directement de suggestions algorithmiques.

2. Etat de l'art

La litterature sur les systemes de recommandation s'organise autour de trois grandes familles d'approches, dont les frontieres se sont estompees au cours de la derniere decennie. Les approches fondees sur le contenu caracterisent chaque element par un vecteur d'attributs et recommandent les elements dont le profil se rapproche de ceux que l'utilisateur a apprecies. Leur atout est l'absence de dependance a la masse critique d'utilisateurs, leur faiblesse la difficulte a faire decouvrir des elements sortant du profil etabli, phenomene designe sous le terme de sur-specialisation. Les approches collaboratives, decrites plus loin, exploitent au contraire la structure des interactions sans rien connaitre du contenu. Les approches hybrides, enfin, combinent les deux signaux selon des schemas varies : ponderation lineaire des scores, cascade ou commutation selon la disponibilite des donnees, ou encore integration des attributs directement dans le modele latent. Les travaux comparatifs recents concluent generalement a la superiorite des hybrides, au prix d'une complexite d'implementation et de reglage sensiblement accrue.

3. Le filtrage collaboratif

Le filtrage collaboratif repose sur une hypothese simple mais puissante : des utilisateurs ayant manifeste des preferences similaires par le passe continueront probablement a partager des gouts similaires. Cette approche presente l'avantage decisif de ne necessiter aucune description du contenu des elements recommandes. Seule la matrice des interactions entre utilisateurs et elements est exploitee, ce qui rend la methode applicable a des domaines ou la caracterisation automatique du contenu serait couteuse ou impossible.

3.1 Methodes fondees sur la memoire

On distingue traditionnellement deux familles au sein du filtrage collaboratif. Les methodes fondees sur la memoire calculent directement des similarites entre lignes ou colonnes de la matrice d'interactions, puis agregent les notes des voisins les plus proches pour predire une note manquante. La similarite cosinus et le coefficient de correlation de Pearson sont les mesures les plus employees. Ces methodes ont pour merite leur interpretabilite : on peut toujours justifier une recommandation en exhibant les utilisateurs voisins qui l'ont motivee. Leur inconvenient est le cout de calcul, qui croit quadratiquement avec le nombre d'utilisateurs.

3.2 Methodes fondees sur un modele

Les methodes fondees sur un modele cherchent au contraire a apprendre une representation latente compacte des utilisateurs et des elements. La factorisation matricielle en est l'exemple canonique : la matrice d'interactions, tres creuse, est approchee par le produit de deux matrices de rang faible. Chaque utilisateur et chaque element se voit ainsi associer un vecteur dans un espace latent de dimension reduite, typiquement quelques dizaines a quelques centaines de composantes. La note predite n'est autre que le produit scalaire des deux vecteurs correspondants. Cette formulation, popularisee lors du prix Netflix, offre un excellent compromis entre qualite de prediction et cout de calcul, et se prete naturellement a une optimisation par descente de gradient stochastique.

3.3 Regularisation et termes de biais

La regularisation constitue le point critique de la factorisation matricielle. La matrice d'interactions etant extremement creuse, souvent moins d'un pour cent de cellules renseignees, un modele de rang meme modere dispose de suffisamment de degres de liberte pour reconstituer parfaitement les observations tout en generalisant tres mal. La penalisation de la norme des vecteurs latents, ponderee par un coefficient determine par validation croisee, est le remede standard. Une raffinement consiste a ponderer cette penalite par le nombre d'observations associees a chaque utilisateur ou element, de sorte que les entites peu observees soient plus fortement contraintes vers l'origine. L'introduction de termes de biais, un par utilisateur et un par element, ameliore systematiquement les resultats en absorbant les effets de niveau : certains utilisateurs notent structurellement plus haut que d'autres, certains elements recueillent des notes uniformement elevees independamment de tout appariement de gouts. Negliger ces biais conduit le modele latent a les représenter implicitement, au detriment de sa capacite a capturer les affinites reelles.

4. Le probleme du demarrage a froid

Le probleme du demarrage a froid constitue la limite structurelle du filtrage collaboratif. Un nouvel utilisateur, sans historique, ne peut etre rapproche d'aucun voisin ; un nouvel element, sans interaction, ne sera jamais recommande. Plusieurs strategies d'atenuation coexistent. La plus directe consiste a solliciter explicitement quelques preferences initiales lors de l'inscription, au risque d'alourdir le parcours. Une autre voie recommande, par default, les elements les plus populaires, ce qui garantit une pertinence moyenne acceptable mais renforce le biais de popularite. Les approches hybrides, enfin, completent le signal collaboratif par des attributs descriptifs des elements et des utilisateurs, seuls disponibles en l'absence d'historique.

5. Jeu de donnees et protocole

Le jeu de donnees retenu comporte un million d'interactions notees, reparties sur environ six mille utilisateurs et quatre mille elements. La distribution du nombre d'interactions par utilisateur suit une loi de puissance marquee : la mediane s'etablit a quelques dizaines d'interactions tandis que le dernier centile depasse le millier. Cette asymetrie a des consequences pratiques importantes. Un decoupage aleatoire uniforme des interactions place systematiquement des elements de chaque utilisateur actif dans les deux ensembles, ce qui surestime la performance mesuree par rapport a la situation reelle ou l'on doit servir des utilisateurs peu connus. Le protocole retenu procede donc par decoupage temporel : les interactions les plus recentes de chaque utilisateur constituent l'ensemble de test, les precedentes l'ensemble d'apprentissage. Ce choix reproduit fidelement les conditions d'exploitation et degrade, comme attendu, les scores rapportes de plusieurs points par rapport a un decoupage naif.

6. Evaluation des recommandations

L'evaluation d'un systeme de recommandation ne se reduit pas a la minimisation d'une erreur de prediction. L'erreur quadratique moyenne, longtemps dominante, mesure la capacite a reconstituer des notes mais ignore la nature ordonnee de la tache reelle : l'utilisateur ne consulte que les premiers elements proposes. Les metriques de classement, precision et rappel a un rang donne, gain cumule actualise normalise, sont donc preferables. Au-dela de la pertinence, la couverture du catalogue, la diversite intra-liste et la nouveaute des suggestions constituent des criteres complementaires indispensables. Un systeme optimisant la seule pertinence tend a concentrer ses recommandations sur une fraction reduite du catalogue, appauvrissant l'experience et fragilisant le modele economique de la plateforme.

7. Le biais de popularite

Le biais de popularite merite un traitement specifique car il s'auto-entretient. Les elements deja populaires recoltent davantage d'interactions, ce qui renforce leur representation dans les donnees d'apprentissage, ce qui accroit leur probabilite d'etre recommandees, ce qui augmente encore leur popularite. A l'echelle de plusieurs cycles de reentrainement, cette boucle appauvrit mecaniquement la diversite du catalogue exploite et enferme les utilisateurs dans un espace de suggestions reduit. Les correctifs proposes agissent a differents niveaux. En amont, un reechantillonnage des donnees d'apprentissage attenu la surrepresentation des elements dominants. Au niveau du modele, une penalisation explicite de la popularite dans la fonction de cout deplace l'optimum vers des recommandations plus equilibrees. En aval, un reordonnement de la liste finale sous contrainte de diversite offre le controle le plus direct, au prix d'une perte de pertinence mesuree qu'il faut accepter. Aucune de ces techniques ne resout le probleme, elles en deplacent le curseur, et le reglage de ce curseur releve d'une decision de produit et non d'un choix technique.

8. Architecture mise en oeuvre

L'architecture retenue separe strictement le calcul hors ligne du service en ligne. Un traitement par lots, execute chaque nuit, reconstruit les representations latentes a partir de l'integralite de

l'historique et les depose dans un magasin de vecteurs indexe. Le service en ligne se limite alors a une recherche des plus proches voisins dans cet espace, operation dont la latence reste compatible avec une reponse synchrone. Cette separation garantit que la montee en charge du service ne depend pas du cout d'apprentissage du modele. Un mecanisme de repli sur les elements populaires protege le service en cas d'indisponibilite du magasin de vecteurs.

9. Retour d'experience sur le deployment

La mise en production a mis en evidence des difficultes que l'evaluation hors ligne ne laissait pas anticiper. La latence du service, satisfaisante en charge nominale, se degrade brutalement lorsque le magasin de vecteurs depasse la memoire disponible et commence a paginer sur disque ; le dimensionnement doit donc etre etabli sur la taille de l'index et non sur le debit de requetes. La surveillance de la derive du modele constitue le second point d'attention : la distribution des interactions evolue continuellement, et un modele fige voit sa pertinence decroitre sans qu'aucune erreur technique ne se manifeste. Un suivi hebdomadaire du taux de clic sur les recommandations, compare a une base de reference constituee de suggestions aleatoires servies a une fraction reduite du trafic, s'est revele le seul indicateur fiable de cette degradation silencieuse.

10. Conclusion

Les travaux presentes montrent qu'une factorisation matricielle correctement regularisee suffit a obtenir des performances competitives sur le jeu de donnees retenu, sans recourir a des architectures neuronales profondes dont le cout d'entrainement serait disproportionne au regard du gain observe. Les perspectives d'amelioration portent moins sur la sophistication du modele que sur la qualite du signal exploite : l'integration des retours implicites, plus abondants que les notes explicites, et la prise en compte de la dimension temporelle des preferences constituent les deux axes les plus prometteurs.