

Aide a la decision clinique par exploitation du dossier patient

Rapport de fin d'etudes - document de test, contenu fictif

1. Introduction

La numerisation des dossiers patients dans les etablissements de sante marocains progresse rapidement, sans que les outils d'exploitation de ces donnees suivent le meme rythme. Un praticien dispose aujourd'hui d'un historique volumineux mais faiblement structure, dont l'analyse manuelle lors d'une consultation est materiellement impossible. Le present travail propose un module d'aide a la decision destine a faire remonter, au moment de la consultation, les elements du dossier statistiquement associes au motif de visite.

2. Contraintes du domaine medical

Le contexte medical impose des contraintes absentes des applications commerciales. La tracabilite de toute suggestion est une exigence reglementaire autant que deontologique : un praticien ne peut fonder une decision sur une recommandation dont l'origine lui echappe. Cette exigence disqualifie d'emblee les modeles dont le raisonnement n'est pas restituable. La confidentialite des donnees interdit par ailleurs tout traitement hors de l'infrastructure de l'etablissement, ce qui exclut les services d'inference distants et contraint fortement les ressources de calcul disponibles.

3. Le filtrage collaboratif

Le filtrage collaboratif repose sur une hypothese simple mais puissante : des utilisateurs ayant manifeste des preferences similaires par le passe continueront probablement a partager des gouts similaires. Cette approche presente l'avantage decisif de ne necessiter aucune description du contenu des elements recommandes. Seule la matrice des interactions entre utilisateurs et elements est exploitee, ce qui rend la methode applicable a des domaines ou la caracterisation automatique du contenu serait couteuse ou impossible.

3.1 Methodes fondees sur la memoire

On distingue traditionnellement deux familles au sein du filtrage collaboratif. Les methodes fondees sur la memoire calculent directement des similarites entre lignes ou colonnes de la matrice d'interactions, puis agregent les notes des voisins les plus proches pour predire une note manquante. La similarite cosinus et le coefficient de correlation de Pearson sont les mesures les plus employees. Ces methodes ont pour merite leur interpretabilite : on peut toujours justifier une recommandation en exhibant les utilisateurs voisins qui l'ont motivee. Leur inconvenient est le cout de calcul, qui croit quadratiquement avec le nombre d'utilisateurs.

3.2 Methodes fondees sur un modele

Les methodes fondees sur un modele cherchent au contraire a apprendre une representation latente compacte des utilisateurs et des elements. La factorisation matricielle en est l'exemple canonique : la matrice d'interactions, tres creuse, est approchee par le produit de deux matrices de rang faible. Chaque utilisateur et chaque element se voit ainsi associer un vecteur dans un espace latent de dimension reduite, typiquement quelques dizaines a quelques centaines de composantes. La note predite n'est autre que le produit scalaire des deux vecteurs correspondants. Cette formulation, popularisee lors du prix Netflix, offre un excellent compromis entre qualite de prediction et cout de calcul, et se prete naturellement a une optimisation par descente de gradient stochastique.

3.3 Regularisation et termes de biais

La regularisation constitue le point critique de la factorisation matricielle. La matrice d'interactions etant extremement creuse, souvent moins d'un pour cent de cellules renseignees, un modele de rang meme modere dispose de suffisamment de degres de liberte pour reconstituer parfaitement les observations tout en generalisant tres mal. La penalisation de la norme des vecteurs latents, ponderee par un coefficient determine par validation croisee, est le remede standard. Une raffinement consiste a ponderer cette penalite par le nombre d'observations associees a chaque utilisateur ou element, de sorte que les entites peu observees soient plus fortement contraintes vers l'origine. L'introduction de termes de biais, un par utilisateur et un par element, ameliore systematiquement les resultats en absorbant les effets de niveau : certains utilisateurs notent structurellement plus haut que d'autres, certains elements recueillent des notes uniformement elevees independamment de tout appariement de gouts. Negliger ces biais conduit le modele latent a les représenter implicitement, au detriment de sa capacite a capturer les affinites reelles.

4. Le probleme du demarrage a froid

Le probleme du demarrage a froid constitue la limite structurelle du filtrage collaboratif. Un nouvel utilisateur, sans historique, ne peut etre rapproche d'aucun voisin ; un nouvel element, sans interaction, ne sera jamais recommande. Plusieurs strategies d'atenuation coexistent. La plus directe consiste a solliciter explicitement quelques preferences initiales lors de l'inscription, au risque d'alourdir le parcours. Une autre voie recommande, par default, les elements les plus populaires, ce qui garantit une pertinence moyenne acceptable mais renforce le biais de popularite. Les approches hybrides, enfin, completent le signal collaboratif par des attributs descriptifs des elements et des utilisateurs, seuls disponibles en l'absence d'historique.

5. Anonymisation et jeu de validation

La construction du jeu de validation a exige un travail d'anonymisation prealable conduit avec le service concerne. Les identifiants directs ont ete remplaces par des pseudonymes stables, les dates decalees d'un intervalle aleatoire constant par patient afin de preserver les durees relatives, et les zones de texte libre ecartees faute de pouvoir garantir l'absence de donnees identifiantes. Cette derniere exclusion ampute significativement l'information disponible, les observations cliniques les plus riches figurant precisement dans ces champs. Le module developpe s'appuie donc uniquement sur les donnees structurees, limitation dont l'incidence

sur la pertinence a ete explicitement documentee.

6. Integration au systeme d'information

L'integration au systeme d'information existant a represente une part substantielle de la charge de travail, sans rapport avec la difficulte algorithmique. Le dossier patient en place expose une interface de consultation mais aucun point d'extension permettant d'afficher un contenu tiers dans le flux de travail du praticien. La solution retenue substitue au poste de travail un module intermediaire qui interroge le dossier, enrichit l'affichage et relaie l'interaction, au prix d'une dependance forte a la version installee du logiciel. Cette contrainte, courante dans le domaine hospitalier, plaide pour l'evaluation prealable de la capacite d'integration avant tout engagement sur les aspects fonctionnels.

7. Protocole de validation

Le protocole de validation associe une evaluation quantitative sur donnees historiques anonymisees et une evaluation qualitative par un panel de praticiens. La premiere mesure la capacite du module a faire remonter les elements effectivement consultes ; la seconde, seule a pouvoir apprecier la pertinence clinique, recueille un jugement structure sur un echantillon de cas. Les resultats convergent sur un point : la pertinence percue depend davantage de la concision de la liste presentee que de son exhaustivite, un praticien ecartant l'ensemble des suggestions des lors que les premieres lui paraissent hors sujet.